

逻辑数据入湖（数据编织）技术可行性调研报告

版本：v1.0（修订版） 编制日期：2026-09-22

范围：开源方案、国内商用产品（信创视角）调研对比，以及基于 Trino 的选型论证与验证方案

说明：商用产品的功能与名录信息会随版本变化，正式选型前需按厂商最新资料与《安全可靠测评结果公告》复核。


0. 摘要

- “逻辑数据入湖”本质是**不搬数据、按需联邦/虚拟化查询**：湖（对象存储 + 开放表格式）作为统一访问面，源系统保留数据主权，查询时下推、跨源 JOIN 由引擎完成。
- 数据编织 (Data Fabric) = 数据虚拟化/联邦查询引擎 + 元数据 (主动元数据) + 治理 (权限/脱敏/血缘) + 语义层 + 按需物化加速**。虚拟化是“发动机”，编织是“整车 + 交通规则”。
- 关键约束 (安可名录)**：安全可靠测评（“国测”）覆盖品类为 CPU、AI 芯片、操作系统、数据库、打印机主控芯片——**数据库被强约束，而查询中间件不在该名录品类内**。因此把“联邦/虚拟化引擎”做成数据库形态、或用某款数据库当引擎，会被名录收敛；用 **Trino 这类中间件**更契合逻辑入湖的“连接与编排”本质。
- 国内商用可重点看**大应数据 Aloudata (AIR 逻辑数据编织平台 + BIG/CAN/Agent)**、星环 Transwarp、华为云 DataArts Studio、阿里云 DataWorks、百分点/数猎天下等。
- 我们已用 **Trino 483 + 自研连接器**验证：跨 **OceanBase / Greenplum / 达梦** 单 SQL JOIN、动态 Catalog、表级权限、元数据发现、查询工作台，端到端 **E2E_OK**。“**基于 Trino 自研**”在功能上成立且可扩展。
- 结论：推荐“**Trino 自研为联邦底座 + 按需外采/自建治理与语义层**”的组合路线。


1. 概念与定位

逻辑入湖与物理入湖的区别：

物理入湖 (ETL/ELT)



逻辑入湖 (Virtualization/Federation)



概念	一句话	关键差别
数据联邦	跨多个库的 SQL JOIN	最基础，通常无治理/语义层
数据虚拟化	统一逻辑层 + 下推 + 缓存	联邦 + 语义/缓存/安全
数据编织 Data Fabric	虚拟化 + 元数据 + 治理 + 主动元数据	面向企业规模的“系统”
数据网格 Data Mesh	组织/权责范式（域自治数据产品）	偏组织架构，可与编织互补
湖仓 Lakehouse	存储/表格式（Iceberg/Delta/Hudi）	逻辑入湖的“落点”

术语对齐：本报告里“逻辑数据入湖” = 以湖仓为统一访问层的虚拟化/联邦；“数据编织” = 在此之上叠加治理与元数据能力的平台形态。

2. 评估维度

用于后文打分与选型：

维度	说明	权重(建议)
连接器覆盖	关系库/数仓/NoSQL/对象存储/SaaS/REST	20%
联邦性能	谓词/投影/聚合下推、CBO、跨源 JOIN、并发	20%
治理与安全	行列级权限、脱敏、审计、多租户	15%
元数据/血缘	目录、血缘、主动元数据、语义层	15%
扩展性	自研连接器、UDF、插件、API	10%
运维/部署/信创	私有化、国产 OS/芯片、HA	10%
生态/成本/自主可控	许可、TCO、代码可控	10%

3. 开源方案调研与对比

方案	定位	联邦/虚拟化	优势	局限
Trino（原 PrestoSQL）	MPP 查询中间件 + 连接器	✅ catalog 即连接器	连接器生态最广、下推成熟、插件化、Apache-2.0 可审计可控、社区活跃、可自研连接器；Iceberg/Delta/Hive 原生	裸引擎缺治理/缓存/语义层；跨源 JOIN 在引擎内做（数据移动）；CBO 依赖统计质量
openLooKeng（华为开源）	面向跨源的联邦引擎	✅ 跨源优化	国产背景、跨源优化	生态/活跃度不及 Trino，社区规模较小
Apache Doris / StarRocks	MPP 数仓	⚠️ 外部 Catalog 联邦（Iceberg/Hive/JDBC）	本地查询强、湖仓联邦	偏“仓”，跨异构实时源编排较弱

方案	定位	联邦/虚拟化	优势	局限
Apache Drill	无 schema 联邦 SQL	⚠️ 有限	对半结构化数据友好	社区放缓、治理/并发弱
Apache Calcite	优化器/联邦框架	—（库）	被众多产品复用	不是成品平台，需自建
Teiid / WildFly	数据虚拟化	✅	开源、容器化	社区小、学习曲线高
DataHub / OpenMetadata / Amundsen	目录/血缘	❌（不是查询引擎）	元数据/血缘	需与联邦引擎组合
SeaTunnel / Flink CDC / Airbyte	数据集成（物理搬运）	❌	同步/CDC 强	属物理入湖，非逻辑层

关键结论：**开源成品主要就是 Trino（可自研/可控）**；治理/目录/语义层需另配，这正是“编织”的缺口，也是自研的着力点。


4. 国内商用产品调研（信创视角，不含国外商用）

产品	厂商	定位	联邦/虚拟化	治理/语义	信创/私有化	备注
Aloudata AIR	大应数据	逻辑数据编织平台（Data Fabric）	✅ 自研国内首个数据虚拟化引擎；联邦查询 + 查询下推 + 自适应关系投影 PRP	四层逻辑建模 PDS/VDWD/V DWS/VADM 、资产目录、行列级权限、动态脱敏、多租户；配套 BIG （主动元数据/算子级血缘）、 CAN （自动化指标）、 Agent （NL2MQL2SQL 问数）	私有化、引擎解耦（可透明换引擎）、100+ 数据源、JDBC/ODBC/REST	NoETL/语义编织 理念；案例：招商银行、首创证券、航司、汽车集团、跨国企业；定位“平台”而非单纯引擎
星环 Transwarp（ArgoDB/Inceptor/TDH）	星环科技	国产大数据/湖仓	✅ 多源联邦/湖仓	较完整治理套件	信创强；ArgoDB V6 入安可 I 级	偏大数据平台底座
华为云 DataArts Studio	华为云	数据开发治理	30+ 源集成；与 DLI/DWS 协同	盘古大模型、字段级血缘、细粒度权限	鲲鹏+欧拉全栈信创 、国密	政务/制造/能源；生态内深度协同
阿里云 DataWorks	阿里云	开发治理平台	50+ 源；MaxCompute/Hologres 一体	AI 运维 Agent、数据分类分级/脱敏	云原生托管， 私有化/信创相对受限	电商/互联网强
腾讯云 WeData	腾讯云	Data+AI 工作台	容器化、语义层	协同治理	信创在建	金融/游戏/互联网

产品	厂商	定位	联邦/虚拟化	治理/语义	信创/私有化	备注
百分点 AI-DG / 数猎天下 DataFormula	百分点 / 数猎天下	智能数据治理/ 编织	元数据 + 多智能体	AI 原生治理	全栈信创、100% 私有化离线	政务/应急/央国企
达梦 / OceanBase / GaussDB / GBase / 人大金仓	各厂商	数据库 (安可名录内)	作为被联邦的“源”	—	名单内, 等级/版本受限	我们要连接的对象

观察：国内“纯逻辑虚拟化引擎”产品较少，多数是“治理/开发平台”形态（偏物理集成 + 治理）；联邦能力往往由底层引擎提供。**Aloudata** 是少数把“数据虚拟化引擎 + 逻辑建模 + 加速”产品化的国内厂商，定位与“逻辑数据入湖”最接近。

5. 综合对比与选型象限



- 要自主可控、可嵌入、连接器可自研 → Trino 自研。
- 要快速获得成熟治理/加速/语义层 → 外采（Aloudata AIR 等）。
- 二者可组合（见第 6 节）。

6. 方案论证：基于 Trino 自研 vs 外采商用产品

6.1 约束前提：安可名录的适用范围

安全可靠测评（业内称“国测”）由中国信息安全测评中心与国家保密科技测评中心联合发布。测评品类为：**CPU（含 AI 加速）、AI 训练推理芯片、操作系统、数据库、打印机主控芯片**。截至 2026 年第 2 号公告（2026-05）已发布四批数据库名单，有效期三年，且条目是**具体产品与版本**（如：达梦 V9 集中式 II 级、达梦分布式 V9 II 级、OceanBase 集中式 V4 I 级、GaussDB、GoldenDB、崖山、Transwarp ArgoDB V6 I 级、GBase 8c 等）。

安可名录覆盖范围

CPU/AI芯片 | 操作系统 | 数据库 | 打印机主控芯片 |

▲
| 数据库被强约束（品类/版本/等级/有效期）
▼

若“联邦/虚拟化引擎”做成数据库形态 → 被名录收敛
查询中间件（Trino 等）不在该名录品类内

6.2 为什么不宜用“基于数据库”的方案

- 1. **名录收敛与版本绑定**：数据库引擎必须落在名录内，且是特定产品 + 版本 + 等级；升级/换代可能触发重新评估，架构被单一数据库厂商绑定。
- 2. **定位错配**：数据库擅长“存 + 本地算”，对**异构源联邦、跨源实时 JOIN、API/NoSQL/对象存储接入能力**弱；逻辑入湖要的是“连接与编排”。
- 3. **“不搬数据”与其本性冲突**：数据库方案容易滑向“再建一个集中库”，重走物理入湖老路。
- 4. **自主可控与接口开放**：数据库联邦层难以自研连接器、难以透明替换；而 Trino 插件化可自研（我们已用达梦连接器验证）。

反过来看：**名录内的数据库**（达梦/OceanBase/GaussDB/GBase 等）**应当是“被联邦的源”，而不是“联邦引擎”**。这正好把引擎与数据源解耦。

6.3 中间件（Trino）为什么更合适

- **不在安可数据库名录品类内** → 不受“必须选名录数据库当引擎”的直接约束；可私有化部署、Apache-2.0 可审计可控。
- **连接器即扩展点**：可连接名录内数据库作为源，也可自研连接器（trino-dameng 已验证）。
- **逻辑入湖的天然形态**：coordinator 规划、worker 执行，谓词/投影/聚合下推，跨源 JOIN 在引擎内完成；湖仓（Iceberg/Hudi/Delta）可原生直读。
- **注意（风险）**：中间件自身仍需满足**信创适配**要求（国产 OS/芯片、国密、等保），但其性质是“适配与安全合规”，**不同于“必须用某款数据库”的名录硬约束**；必要时可选国产衍生（openLooKeng）或代码托管/审计方案。

6.4 自研 vs 外采：决策矩阵

维度	基于 Trino 自研	外采商用（Aloudata AIR 等）
自主可控/信创	高（代码可控、连接器自研、私有化）	中（依赖厂商，私有化看产品）
能力完整度（建模/加速/治理/语义）	低（需自建）	高（逻辑建模、PRP 加速、行列级安全、语义层）
交付速度	慢（引擎 + 治理都要做）	快
TCO	低（开源 + 自研人力）	中高（授权 + 服务）
性能上限	取决于下推/统计/物化（需自建加速）	有成熟加速（如自适应关系投影）
扩展性	强（插件/连接器/UDF）	受产品能力边界约束

维度	基于 Trino 自研	外采商用 (Aloudata AIR 等)
团队要求	需引擎/连接器专家	平台使用 + 少量集成
供应商风险	低	中 (锁定/服务连续性)

6.5 已完成的 Trino 自研验证 (实证)

验证项	结果	证据
版本基线	Trino 483 引擎/镜像/客户端一致	version-alignment spec
跨源联邦	OceanBase + Greenplum + 达梦 单 SQL JOIN	E2E E2E_OK, 返回 [[1,'alice',100], [2,'bob',200]]
连接器可扩展	自研 trino-dameng 插件 (BaseJdbcClient, SPI 483)	日志 Registering connector dameng
动态 Catalog	平台注册即 CREATE CATALOG, 停用即 DROP	数据源生命周期 E2E
下推验证	谓词下推 (constraint on [id], 无 Filter)	查询 E2E
表级权限	grant/revoke; JOIN/子查询/CTE 越权被拒	权限 E2E (引擎强制)
元数据	information_schema 由 Trino 合成 (达梦无原生 info schema 也 OK)	达梦 columns/detail E2E
规模化	万行返回; 超 max-rows 截断	[perf] E2E
工作台	编辑器/对象树/结果栅格/图表/历史/收藏	sql-editor / query-result-grid / query-history spec

6.6 待补测矩阵与路线建议

类别	待验证	指标
性能	跨源 JOIN、聚合下推、下推边界	QPS、P95、源端负载; 明确 “可下推 vs 需数据移动”
并发	1/10/50 并发	失败率、内存/GC, 无 OOM
优化器	统计信息质量	ANALYZE 覆盖率、join reorder
治理	列级权限/脱敏/审计	越权不可见/不可查
血缘/语义	与 DataHub/OpenMetadata 集成或自建	列级血缘可用
加速	热点物化 (Iceberg/关系投影)	热点查询显著加速
信创	国产 OS/芯片、达梦/OceanBase 适配	目标环境全链路可运行

路线建议 (分阶段)

- 1. 自研 Trino 打通 “连接 + 联邦 + 目录 + 基础权限” (已完成)。
- 2. 视治理/加速诉求, 外采逻辑层/加速/语义组件 (如 Aloudata AIR) 或自建, 保持接口开放、引擎可替换。

- 3. 热点场景**按需物化**到湖仓，形成“虚拟化默认 + 物化加速”的混合模式。
- 4. 完成信创适配（国产 OS/芯片/数据库作为源）与 HA 演练。

6.7 结论

- 数据库方案受安可名录约束，不宜作为联邦/虚拟化引擎；中间件（Trino）不在该名录品类，天然更契合逻辑入湖的“连接与编排”定位。
- “基于 Trino 自研”**技术可行且已实证**；“外采商用产品”（尤其 Aloudata AIR 这类逻辑数据编织平台）可在治理/加速/语义层快速补齐。
- 推荐“**Trino 自研为底座 + 按需外采/自建治理与语义**”的组合路线。

附录 A：术语表

术语	含义
逻辑入湖	不物理搬运数据，通过联邦/虚拟化按需查询湖与源
数据编织 Data Fabric	虚拟化 + 主动元数据 + 治理 + 语义的架构与平台
数据虚拟化	统一逻辑层 + 下推 + 缓存/物化
联邦查询	跨源 SQL JOIN 的查询技术
RP / PRP	Relational Projection / 自适应关系投影，Aloudata 的物化加速机制
安可/国测	安全可靠测评及其结果公告，覆盖 CPU/OS/数据库/AI 芯片/打印机芯片
信创	信息技术应用创新（国产化替代）

附录 B：参考来源（需按最新版本复核）

- Trino 官方发布说明（483 / 2026-07）。
- 安全可靠测评结果公告（2026 年第 2 号，2026-05-26），中国信息安全测评中心 / 国家保密科技测评中心。
- 大应数据 Aloudata 官网：AIR 逻辑数据编织平台、BIG 主动元数据、CAN 指标、Agent 等产品资料。
- 华为云 DataArts Studio、阿里云 DataWorks、腾讯云 WeData、星环 Transwarp、百分点/数猎天下等公开资料。
- 本仓库 data-fabric 原型的 E2E 与 OpenSpec 规格（[openspec/specs/*](#)）。